

MVP de Engenharia de Dados

Risco de Ruptura de Estoque no Varejo

Nome: Renata Virginia | Matrícula: 4052025002400
Plataforma: Databricks Free Edition | Dataset: Retail Store Inventory Forecasting (Kaggle, CC0)

1. Contexto de Negócios e Perguntas (Etapa 2 e 4.1)

Problema

Uma empresa varejista precisa garantir a disponibilidade dos produtos para atender a demanda. A ocorrência de níveis insuficientes de estoque resulta em **ruptura**, perda de vendas e pior experiência para o consumidor. Ao mesmo tempo, estoques excessivos aumentam custos e capital imobilizado.

O objetivo deste projeto é construir um pipeline de dados capaz de identificar padrões associados ao **risco de ruptura de estoque** e gerar informações que apoiem decisões de abastecimento.

Dataset

Nome: Retail Store Inventory Forecasting Dataset
Fonte: Kaggle (Anirudh Chauhan)
Licença: CC0 (Public Domain) — uso livre, sem necessidade de atribuição
Volume: 73.100 registros diários | **Período:** 2022-01-01 a 2024-01-01
Conteúdo: Lojas, produtos, vendas, estoques, preços, promoções, feriados e clima

Estrutura dos dados brutos

Coluna original	Tipo	Descrição
Store ID	String	Identificador da loja
Product ID	String	Identificador do produto
Category	String	Categoria do produto
Region	String	Região geográfica
Date	String	Data do registro
Inventory Level	Integer	Nível de estoque disponível
Units Sold	Integer	Unidades vendidas no dia
Units Ordered	Integer	Unidades pedidas/repostas
Demand Forecast	Double	Previsão de demanda
Price	Double	Preço unitário
Discount	Double	Desconto aplicado
Weather Condition	String	Condição climática
Holiday/Promotion	String	Indicador de feriado ou promoção
Competitor Pricing	Double	Preço do concorrente
Seasonality	String	Estação do ano

Regra de negócio: Estoque Crítico

```
flag_estoque_critico = True    quando    dias_cobertura < 7  
dias_cobertura = nivel_estoque / demanda_media_7d
```

Justificativa: O critério de 7 dias de cobertura é padrão de mercado para varejo de ciclo curto. Abaixo desse limiar, o estoque está em zona de risco iminente de ruptura antes do próximo ciclo.

Perguntas de negócio

#	Pergunta
P1	Quais produtos, categorias e lojas tem maior frequência de estoque crítico?
P2	Ha relação entre alto volume de vendas e maior risco de estoque crítico?
P3	Promoções aumentam a pressão sobre o estoque e geram mais eventos críticos?
P4	Feriados e períodos específicos apresentam maior pressão sobre o estoque?
P5	Ha relação entre preco do produto e risco de estoque crítico? (complementar)

2. Carga dos Dados (Etapa 4.2)

O dataset esta disponível como tabela Delta gerenciada no Unity Catalog: `workspace.default.retail_store_inventory`

Como foi feita a carga

1. Download do arquivo `retail_store_inventory.csv` do Kaggle (CC0)
2. Ingestão como tabela Delta no Unity Catalog
3. Leitura com PySpark via `spark.table()` no notebook `01_bronze_ingestao.py`
4. Renomeação das colunas para `snake_case` (compatibilidade com Delta Lake)
5. Adição dos metadados `ingestion_date` e `source_table`
6. Gravação na camada Bronze: `workspace.bronze.inventory_raw` — **73.100 registros**

Script: `notebooks/01_bronze_ingestao.py` (repositório GitHub)

Evidência: [OK] `workspace.bronze.inventory_raw` gravada com 73,100 registros

3. Modelagem e Catálogo de Dados (Etapa 4.3)

Arquitetura Medallion

Bronze (dado bruto)	->	Silver (limpo e padronizado)	->	Gold (modelado para análise)
inventory_raw		inventory_clean		fato_estoque_diario
				dim_produto / dim_loja / dim_data

Esquema Estrela (camada Gold)

	+-----+	
	dim_data id_data, data_completa, ano, mes,	
	731 linhas trimestre, dia_semana, nome_mes, feriado	
	+-----+	
+-----+	+-----+	+-----+
dim_produto	fato_estoque_diario	dim_loja
100 linhas	<- 1.462.000 linhas	>- 20 linhas
+-----+		+-----+
id_produto (PK)	id_produto / id_loja	id_loja (PK)
produto_id_orig	id_data	loja_id_orig
nome_produto	unidades_vendidas	nome_loja
categoria	nivel_estoque	regiao
	preco_unitario / desconto	
	em_promocao / feriado	
	demand_media_7d (calc.)	
	dias_cobertura (calc.)	
	flag_estoque_critico (calc.)	
	+-----+	

Catálogo de Dados

bronze.inventory_raw — 73.100 registros

Coluna	Tipo	Descrição
store_id	String	Identificador da loja
product_id	String	Identificador do produto
category / region	String	Categoria e região geografica
date	Date	Data do registro
inventory_level	Integer	Nível de estoque disponível
units_sold / units_ordered	Integer	Vendas e reposições do dia
price / discount	Double	Preco e desconto unitario
weather_condition	String	Condição climatica
holiday_promotion	String	Indicador de feriado ou promoção
competitor_pricing / seasonality	Double/String	Preco concorrente e estação
ingestion_date	Timestamp	Data/hora da ingestão (metadado)
source_table	String	Tabela de origem no Unity Catalog (metadado)

silver.inventory_clean — 73.100 registros

Coluna	Tipo	Descrição
loja_id / produto_id	String	Identificadores
categoria / região / sazonalidade	String	Em uppercase
data	Date	Data do registro
nivel_estoque / unidades_vendidas / unidades_pedidas	Integer	Volumes do dia
preco_unitario / desconto / preco_concorrente	Double	Precos
condicao_climatica	String	Condição climatica
em_promocao / feriado	Boolean	Separado de holiday_promotion

gold.fato_estoque_diario — 1.462.000 registros

Coluna	Tipo	Linhagem
id_data / id_produto / id_loja	Integer	Chaves FK para as dimensões
nivel_estoque / unidades_vendidas	Integer	Silver: colunas correspondentes
preco_unitario / em_promocao / feriado	Double/Boolean	Silver: colunas correspondentes
demandas_media_7d	Double	Calculado via Window Function (7 dias)
dias_cobertura	Double	Calculado: nivel_estoque / demandas_media_7d
flag_estoque_critico	Boolean	Calculado: dias_cobertura < 7

4. Pipeline de Dados (Etapa 4.4)

O pipeline foi organizado em **5 notebooks separados por responsabilidade**, seguindo a Arquitetura Medallion.

Notebook	Camada	Responsabilidade
01_bronze_ingestao.py	Bronze	Leitura da tabela de origem e gravação sem transformações
02_silver_transformacao.py	Silver	Limpeza, padronização e remoção de duplicatas
03_gold_modelagem.py	Gold	Esquema Estrela e aplicação da regra de ruptura
04_qualidade_dados.py	Bronze/Silver/Gold	Verificação de qualidade nas três camadas
05_analise_negocio.py	Gold	Resposta as 5 perguntas com visualizações

Também foi criado o `00_pipeline_completo.py` que executa todas as etapas em sequência.

Transformações (Silver)

Transformação	Decisão
Renomeação de colunas	Nomes padronizados em portugues
Conversão de tipos	<code>data</code> para <code>DateTime</code> , <code>numericos</code> para <code>Int/Double</code>
Separação feriado/promoção	<code>holiday_promotion</code> separada em <code>em_promocao</code> e <code>feriado</code>
Padronização strings	Trim + uppercase em categorias, regiões e sazonalidade
Duplicatas	Removidas por chave <code>loja_id + produto_id + data</code>
Nulos essenciais	Linhas com <code>nivel_estoque</code> ou <code>unidades_vendidas</code> nulos removidas
Valores impossíveis	Estoque/vendas negativos e preço zero removidos

Evidência: tabelas salvas no Databricks

```
=== Contagem por tabela Gold ===
dim_produto      :      100
dim_loja         :       20
dim_data         :      731
fato_estoque_diario : 1,462,000

=== Integridade referencial (chaves nulas na fato) ===
id_produto nulos: 0  [OK]
id_loja nulos  : 0  [OK]
id_data nulos  : 0  [OK]

Bronze: workspace.bronze.inventory_raw    -> 73,100 registros [OK]
Silver: workspace.silver.inventory_clean  -> 73,100 registros [OK]
Gold:   workspace.gold.fato_estoque_diario -> 1,462,000 registros [OK]
```

5. Qualidade de Dados (Etapa 4.5)

Completude: Valores Nulos

```
BRONZE: inventory_raw | 73,100 registros | [OK] Todas as colunas -> 0 nulos (0.0%)
SILVER: inventory_clean| 73,100 registros | [OK] Todas as colunas -> 0 nulos (0.0%)
GOLD:   fato_estoque   | 1,462,000 reg.   | [OK] Todas as colunas -> 0 nulos (0.0%)
```

Unicidade: Duplicatas

```
Total de registros      : 73,100
Chaves unicas           : 73,100  (loja_id + produto_id + data)
Duplicatas detectadas: 0
[OK] Nenhuma duplicata encontrada.
```

Consistência: Domínios e Formatos

```
Faixa de datas: 2022-01-01 a 2024-01-01 (2 anos completos)
Categorias (5): CLOTHING | ELECTRONICS | FURNITURE | GROCERIES | TOYS
Regioes (4):     EAST | NORTH | SOUTH | WEST
Clima:           Rainy | Snowy | Sunny | Windy
Sazonalidade:    FALL | SPRING | SUMMER | WINTER
```

Acurácia e Outliers

```
Valores impossiveis:
  Estoque negativo      : 0 [OK]
  Vendas negativas      : 0 [OK]
  Preço zero ou negativo: 0 [OK]
  Cobertura negativa    : 0 [OK]

Estatisticas descritivas (Silver):
  nivel_estoque      | media: 274.5 | min: 0 | max: 1000
  unidades_vendidas  | media: 136.5 | min: 0 | max: 400
  preco_unitario     | media: 50.0  | min: 10.0 | max: 100

Distribuicao da flag de estoque critico:
  true  (critico): 1,455,200 registros (99.53%)
  false (normal) : 6,800 registros ( 0.47%)


< 7 dias  (critico) : 1,455,200
7-14 dias (atencao) : 6,480
14-30 dias (ok)    : 260
```

6. Análise de Dados (Etapa 4.5)

Nota: Por ser um dataset sintético, a taxa de estoque crítico e uniforme (aprox. 99.5%) em praticamente todas as dimensões. Isso indica que os dados foram gerados com níveis de estoque cronicamente baixos em relação a demanda, o que representa um cenário de ruptura generalizada.


P1.1: Taxa de estoque crítico por categoria

categoria	total_dias	dias_criticos	pct_critico
CLOTHING	292,400	291,040	99.5%
TOYS	292,400	291,040	99.5%
FURNITURE	292,400	291,040	99.5%
GROCERIES	292,400	291,040	99.5%
ELECTRONICS	292,400	291,040	99.5%



Todas as categorias apresentam taxa idêntica (99.5%), confirmando que o problema é sistêmico. Em um cenário real, essa uniformidade sinalizaria necessidade de revisar a política de reposição em toda a rede.


P1.2: Top 15 produtos com maior taxa crítica



Os produtos do Top 15 refletem a mesma uniformidade das categorias. Em dados reais, produtos de maior giro mostrariam taxas mais elevadas.

P1.3: Estoque crítico por loja e região

P1: Estoque crítico por loja e região




Todas as lojas e regiões apresentam taxas equivalentes. O problema não e geograficamente concentrado, confirmando que a causa raiz esta na politica de reposição global.

P2: Relação entre volume de vendas e risco de ruptura

faixa_demanda	total_reg	taxa_ruptura	estoque_medio	vendas_medias
Baixa demanda (< P75)	1,090,940	99.4%	236.7	83.1
Alta demanda (>= P75)	371,060	100.0%	385.6	293.5


P2: Relação entre demanda e risco de estoque crítico



Produtos de alta demanda atingem 100% de criticidade. A diferença e marginal mas confirma: maior giro pressiona mais o estoque. Alta demanda tem estoque medio maior (385.6 vs 236.7), mas insuficiente para cobrir 7 dias.


P3: Impacto das promoções sobre o estoque

rotulo	taxa_critico	vendas_medias	estoque_medio
Com promocao	99.5%	136.42	274.92
Sem promocao	99.5%	136.51	274.03



Promoções não geraram impacto mensuravel. As taxas e vendas médias são praticamente identicas. No dataset sintetico a variavel promoção não foi correlacionada com aumento de demanda.

P4.1: Variação mensal da taxa de estoque crítico




O gráfico mostra a taxa de estoque crítico por mes. Meses com taxas acima da média são candidatos prioritarios para reforco preventivo de estoque antes do período.

P4.2: Feriados vs dias normais

rotulo	total	criticos	taxa	vendas_medias
Dia normal	1,462,000	1,455,200	99.5%	136.46

P4: Feriados vs dias normais




O dataset utilizou holiday_promotion com valores 0/1. Após separação, todos os registros foram classificados como dias normais. A estrutura esta preparada para analisar esse impacto com dados reais.

P5: Relação entre preco e risco de estoque crítico (complementar)

faixa_preco	taxa	vendas_medias
Alto preco (> P75)	99.5%	136.82
Baixo preco (<= P25)	99.5%	135.83
Medio preco (P25-P75)	99.6%	136.59

Variacao de precos: min 10.0 | max 100.0 | desvio padrao 26.02

P5: Taxa de estoque crítico por faixa de preço



Apesar da variação real de precos (desvio padrão 26.02), as taxas de ruptura são identicas entre faixas. O preco não e um fator discriminante neste dataset sintetico.

Conclusão Geral

As cinco análises revelam ruptura **generalizada e uniforme** (aprox. 99.5%), sem diferenciação significativa por categoria, produto, loja, região, promoção ou preço.

Recomendações: revisar a política de reposição para aumentar o estoque de segurança, definir pontos de reposição baseados na demanda média real e monitorar continuamente o indicador `dias_cobertura` com alertas quando cair abaixo de 7 dias.

7. Autoavaliação

O que foi atingido

- Pipeline completo Bronze > Silver > Gold implementado em notebooks separados
- Regra de negócio para estoque crítico definida, documentada e justificada
- Esquema Estrela com tabela fato e 3 dimensões
- Catálogo de dados completo com tipos, descrições e linhagem
- Verificação de qualidade em 5 dimensões
- 5 perguntas de negócio respondidas com análises e visualizações em Python

O que ficou limitado

- **Catálogo no Unity Catalog:** documentado no README, mas não preenchido na interface da plataforma.
- **P3 e P4.2:** dataset sintético sem variação nos campos de promoção e feriado que permitisse diferenciação.

Dificuldades encontradas

- **Delta Lake com espaços nos nomes de colunas:** erro `DELTA_INVALID_CHARACTERS_IN_COLUMN_NAMES`.
Solução: renomear para `snake_case` antes do `saveAsTable`.
- **Window function com coluna DATE:** `.cast("long")` não suportado. Solução: substituir por `.orderBy("data")`.
- **Coluna ambigua no join:** feriado presente em `fato` e `dim_data`. Solução: `.drop("feriado")` antes do `join`.
- **Databricks Free Edition:** sem recurso de publicação de notebooks com link público.

Trabalhos futuros

- Preencher descrições das tabelas diretamente no Unity Catalog
- Criar alertas automáticos para produtos com `dias_cobertura < 7` usando Databricks Workflows
- Explorar modelos de previsão de demanda (Prophet, ARIMA) para antecipar rupturas sazonais
- Construir dashboard interativo no Databricks SQL com atualização diária