

MVP de Engenharia de Dados

Risco de Ruptura de Estoque no Varejo

Nome: Renata Virginia | Matricula: 4052025002400
Plataforma: Databricks Free Edition | Dataset: Retail Store Inventory Forecasting (Kaggle, CC0)

1. Contexto de Negocios e Perguntas (Etapa 2 e 4.1)

Problema

Uma empresa varejista precisa garantir a disponibilidade dos produtos para atender a demanda. A ocorrencia de niveis insuficientes de estoque resulta em **ruptura**, perda de vendas e pior experiencia para o consumidor. Ao mesmo tempo, estoques excessivos aumentam custos e capital imobilizado.

O objetivo deste projeto e construir um pipeline de dados capaz de identificar padroes associados ao **risco de ruptura de estoque** e gerar informacoes que apoiem decisoes de abastecimento.


Dataset

Nome: Retail Store Inventory Forecasting Dataset
Fonte: Kaggle (Anirudh Chauhan)
Licenca: CC0 (Public Domain) — uso livre, sem necessidade de atribuicao
Volume: 73.100 registros diarios | **Periodo:** 2022-01-01 a 2024-01-01
Conteudo: Lojas, produtos, vendas, estoques, precos, promocoes, feriados e clima

Estrutura dos dados brutos

Coluna original	Tipo	Descricao
Store ID	String	Identificador da loja
Product ID	String	Identificador do produto
Category	String	Categoria do produto
Region	String	Regiao geografica
Date	String	Data do registro
Inventory Level	Integer	Nivel de estoque disponivel
Units Sold	Integer	Unidades vendidas no dia
Units Ordered	Integer	Unidades pedidas/repostas
Demand Forecast	Double	Previsao de demanda
Price	Double	Preco unitario
Discount	Double	Desconto aplicado
Weather Condition	String	Condicao climatica
Holiday/Promotion	String	Indicador de feriado ou promocao
Competitor Pricing	Double	Preco do concorrente
Seasonality	String	Estacao do ano

Esquema Estrela (camada Gold)



Catalogo de Dados

bronze.inventory_raw — 73.100 registros. Dado bruto preservado como veio da fonte; colunas renomeadas para snake_case e metadados adicionados.

Coluna	Tipo	Dominio	Descrição
store_id	String	"S001" - "S020" (20 lojas)	Identificador da loja
product_id	String	"P001" - "P100" (100 produtos)	Identificador do produto
category	String	Texto livre - dado bruto	Categoria do produto
region	String	Texto livre - dado bruto	Região geográfica da loja
date	String	Formato "YYYY-MM-DD"	Data do registro
inventory_level	Integer	Sem restrição - dado bruto	Nível de estoque disponível
units_sold	Integer	Sem restrição - dado bruto	Unidades vendidas no dia
units_ordered	Integer	Sem restrição - dado bruto	Unidades pedidas/repostas no dia
demand_forecast	Double	Sem restrição - dado bruto	Previsão de demanda
price	Double	Sem restrição - dado bruto	Preço unitário do produto
discount	Double	Sem restrição - dado bruto	Desconto aplicado
weather_condition	String	Texto livre - dado bruto	Condição climática do dia
holiday_promotion	String	Texto livre - combinação feriado/promoção	Indicador combinado de feriado ou promoção
competitor_pricing	Double	Sem restrição - dado bruto	Preço do concorrente
seasonality	String	Texto livre - dado bruto	Estação do ano
ingestion_date	Timestamp	Data/hora da execução do pipeline	Data/hora da ingestão (metadado)

source_table	String	Sempre "workspace.default.retail_store_inventory"	Tabela de origem no Unity Catalog (metadado)
--------------	--------	--	---

silver.inventory_clean — 73.100 registros. Dados limpos, tipados e padronizados. Registros invalidos removidos; nulos secundarios substituidos por valores padrao.

Coluna	Tipo	Dominio	Descricao
loja_id	String	"S001" - "S020" (20 lojas unicas)	Identificador da loja
produto_id	String	"P001" - "P100" (100 produtos unicos)	Identificador do produto
categoria	String	CLOTHING ELECTRONICS FURNITURE GROCERIES TOYS	Categoria do produto (uppercase)
regiao	String	EAST NORTH SOUTH WEST	Regiao geografica da loja (uppercase)
data	Date	2022-01-01 a 2024-01-01	Data do registro
nivel_estoque	Integer	>= 0 (negativos removidos)	Estoque disponivel no dia
unidades_vendidas	Integer	>= 0 (negativos removidos)	Unidades vendidas no dia
unidades_pedidas	Integer	>= 0	Unidades pedidas/repostas no dia
previsao_demanda	Double	>= 0 (nulos → 0)	Previsao de demanda para o dia
preco_unitario	Double	> 0 (preco <= 0 removido)	Preco unitario do produto
desconto	Double	>= 0 (nulos → 0)	Desconto aplicado no dia
condicao_climatica	String	Rainy Snowy Sunny Windy "NAO_INFORMADO"	Condicao climatica do dia
feriado_ou_promocao	Integer	Valor bruto - base para derivar em_promocao e feriado	Indicador combinado original (coluna preservada)
em_promocao	Boolean	True / False	Se havia promocao ativa (derivado de feriado_ou_promocao)
feriado	Boolean	True / False	Se o dia era feriado (derivado de feriado_ou_promocao)
preco_concorrente	Double	>= 0 (nulos → 0)	Preco praticado pelo concorrente
sazonalidade	String	FALL SPRING SUMMER WINTER	Estacao do ano (uppercase)

gold.dim_produto — 100 registros

Coluna	Tipo	Dominio	Descricao	Linhagem
id_produto	Integer	>= 0 (surrogate key)	Chave primaria (PK)	Gerado: monotonically_increasing_id()
produto_id_orig	String	"P001" - "P100"	Codigo original do produto	Silver: produto_id
nome_produto	String	"P001" - "P100"	Nome do produto	Silver: produto_id
categoria	String	CLOTHING ELECTRONICS FURNITURE GROCERIES TOYS	Categoria do produto	Silver: categoria

gold.dim_loja — 20 registros

Coluna	Tipo	Dominio	Descricao	Linhagem
id_loja	Integer	>= 0 (surrogate key)	Chave primaria (PK)	Gerado: monotonically_increasing_id()
loja_id_orig	String	"S001" - "S020"	Codigo original da loja	Silver: loja_id
nome_loja	String	"S001" - "S020"	Nome da loja	Silver: loja_id
regiao	String	EAST NORTH SOUTH WEST	Regiao geografica	Silver: regiao

gold.dim_data — 731 registros

Coluna	Tipo	Dominio	Descricao	Linhagem
id_data	Integer	Formato yyyyMMdd (ex: 20220101)	Chave primaria (PK)	Gerado: date_format(data, "yyyyMMdd")
data_completa	Date	2022-01-01 a 2024-01-01	Data completa	Silver: data
ano	Integer	2022, 2023, 2024	Ano	Extraido de data_completa
mes	Integer	1 - 12	Numero do mes	Extraido de data_completa
nome_mes	String	January - December	Nome do mes por extenso	Extraido de data_completa
dia_semana	Integer	1 (domingo) - 7 (sabado)	Dia da semana (padrao Spark)	Extraido de data_completa
trimestre	Integer	1 - 4	Trimestre do ano	Extraido de data_completa
feriado	Boolean	True / False	Se o dia era feriado	Silver: feriado

gold.fato_estoque_diario — 73.100 registros

Coluna	Tipo	Dominio	Descricao	Linhagem
id_data	Integer	Formato yyyyMMdd (FK → dim_data)	Referencia a dimensao data	Silver: data
id_produto	Integer	>= 0 (FK → dim_produto)	Referencia a dimensao produto	Silver: produto_id
id_loja	Integer	>= 0 (FK → dim_loja)	Referencia a dimensao loja	Silver: loja_id
nivel_estoque	Integer	>= 0	Estoque disponivel no dia	Silver: nivel_estoque
unidades_vendidas	Integer	>= 0	Quantidade vendida no dia	Silver: unidades_vendidas
unidades_pedidas	Integer	>= 0	Quantidade pedida/reposta no dia	Silver: unidades_pedidas
preco_unitario	Double	> 0	Preco unitario do produto	Silver: preco_unitario
desconto	Double	>= 0	Desconto aplicado no dia	Silver: desconto
em_promocao	Boolean	True / False	Se havia promocao ativa	Silver: em_promocao
feriado	Boolean	True / False	Se o dia era feriado	Silver: feriado
condicao_climatica	String	Rainy Snowy Sunny Windy "NAO_INFORMADO"	Condicao climatica	Silver: condicao_climatica
sazonalidade	String	FALL SPRING SUMMER WINTER	Estacao do ano	Silver: sazonalidade
previsao_demanda	Double	>= 0	Previsao de demanda para o dia	Silver: previsao_demanda
preco_concorrente	Double	>= 0	Preco do concorrente	Silver: preco_concorrente
demanda_media_7d	Double	>= 0	Media movel 7 dias de unidades_vendidas por produto+loja	Calculado: avg(unidades_vendidas) — Window 7 dias
dias_cobertura	Double	0 a 999 (999 = sem demanda)	Dias ate esgotamento do estoque	Calculado: nivel_estoque / demanda_media_7d
flag_estoque_critico	Boolean	True quando dias_cobertura < 7	Indicador de risco de ruptura	Calculado: dias_cobertura < 7

Evidencias no Unity Catalog (Databricks)

As tabelas foram criadas e registradas no Unity Catalog do Databricks Free Edition sob o catalogo [workspace](#). As capturas de tela completas constam na versao HTML deste relatorio.

Schema	Tabela(s)	Registros
workspace.bronze	inventory_raw	73.100
workspace.silver	inventory_clean	73.100
workspace.gold	dim_produto, dim_loja, dim_data, fato_estoque_diario	100 / 20 / 731 / 73.100

4. Pipeline de Dados (Etapa 4.4)

O pipeline foi organizado em **5 notebooks separados por responsabilidade**, seguindo a Arquitetura Medallion.

Notebook	Camada	Responsabilidade
01_bronze_ingestao.py	Bronze	Leitura da tabela de origem e gravacao sem transformacoes
02_silver_transformacao.py	Silver	Limpeza, padronizacao e remocao de duplicatas
03_gold_modelagem.py	Gold	Esquema Estrela e aplicacao da regra de ruptura
04_qualidade_dados.py	Bronze/Silver/Gold	Verificacao de qualidade nas tres camadas
05_analise_negocio.py	Gold	Resposta as 5 perguntas com visualizacoes

Tambem foi criado o 00_pipeline_completo.py que executa todas as etapas em sequencia.

Transformacoes (Silver)

Transformacao	Decisao
Renomeacao de colunas	Nomes padronizados em portugues
Conversao de tipos	data para DateType, numericos para Int/Double
Separacao feriado/promocao	holiday_promotion separada em em_promocao e feriado
Padronizacao strings	Trim + uppercase em categorias, regioes e sazonalidade
Duplicatas	Removidas por chave loja_id + produto_id + data
Nulos essenciais	Linhas com nivel_estoque ou unidades_vendidas nulos removidas
Valores impossiveis	Estoque/vendas negativos e preco zero removidos

Evidencia: tabelas salvas no Databricks

```
=== Contagem por tabela Gold ===
dim_produto      :      100
dim_loja         :       20
dim_data         :      731
fato_estoque_diario : 1,462,000

=== Integridade referencial (chaves nulas na fato) ===
id_produto nulos: 0  [OK]
id_loja nulos  : 0  [OK]
id_data nulos  : 0  [OK]

Bronze: workspace.bronze.inventory_raw    -> 73,100 registros [OK]
Silver: workspace.silver.inventory_clean  -> 73,100 registros [OK]
Gold:   workspace.gold.fato_estoque_diario -> 1,462,000 registros [OK]
```

Evidencia de persistencia das tabelas na plataforma de nuvem

Os tres schemas (bronze, silver e gold) foram persistidos no catalogo workspace do Databricks Free Edition em formato Delta Lake gerenciado. As capturas de tela do Unity Catalog constam na versao HTML deste relatorio.

5. Qualidade de Dados (Etapa 4.5)

Completude: Valores Nulos

```
BRONZE: inventory_raw | 73,100 registros | [OK] Todas as colunas -> 0 nulos (0.0%)
SILVER: inventory_clean| 73,100 registros | [OK] Todas as colunas -> 0 nulos (0.0%)
GOLD:   fato_estoque   | 1,462,000 reg.   | [OK] Todas as colunas -> 0 nulos (0.0%)
```

Unicidade: Duplicatas

```
Total de registros      : 73,100
Chaves unicas           : 73,100 (loja_id + produto_id + data)
Duplicatas detectadas: 0
[OK] Nenhuma duplicata encontrada.
```

Consistencia: Dominios e Formatos

```
Faixa de datas: 2022-01-01 a 2024-01-01 (2 anos completos)
Categorias (5): CLOTHING | ELECTRONICS | FURNITURE | GROCERIES | TOYS
Regioes (4):    EAST | NORTH | SOUTH | WEST
Clima:          Rainy | Snowy | Sunny | Windy
Sazonalidade:   FALL | SPRING | SUMMER | WINTER
```

Acuracia e Outliers

```
Valores impossiveis:
Estoque negativo      : 0  [OK]
Vendas negativas      : 0  [OK]
Preco zero ou negativo : 0  [OK]
Cobertura negativa    : 0  [OK]

Estatisticas descritivas (Silver):
nivel_estoque | media: 274.5 | min: 0 | max: 1000
unidades_vendidas | media: 136.5 | min: 0 | max: 400
preco_unitario  | media: 50.0 | min: 10.0 | max: 100

Distribuicao da flag de estoque critico:
true (critico): 1,455,200 registros (99.53%)
false (normal) : 6,800 registros ( 0.47%)

< 7 dias (critico) : 1,455,200
7-14 dias (atencao) : 6,480
14-30 dias (ok) : 260
```

6. Analise de Dados (Etapa 4.5)

Nota: Por ser um dataset sintetico, a taxa de estoque critico e uniforme (aprox. 99.5%) em praticamente todas as dimensoes. Isso indica que os dados foram gerados com niveis de estoque cronicamente baixos em relacao a demanda, o que representa um cenario de ruptura generalizada.

P1.1: Taxa de estoque critico por categoria

categoria	total_dias	dias_criticos	pct_critico
CLOTHING	292,400	291,040	99.5%
TOYS	292,400	291,040	99.5%
FURNITURE	292,400	291,040	99.5%
GROCERIES	292,400	291,040	99.5%
ELECTRONICS	292,400	291,040	99.5%

Todas as categorias apresentam taxa identica (99.5%), confirmando que o problema e sistematico. Em um cenario real, essa uniformidade sinalizaria necessidade de revisar a politica de reposicao em toda a rede.

P1.2: Top 15 produtos com maior taxa critica

Os produtos do Top 15 refletem a mesma uniformidade das categorias. Em dados reais, produtos de maior giro mostrariam taxas mais elevadas.

P1.3: Estoque critico por loja e regioao

Todas as lojas e regioes apresentam taxas equivalentes. O problema nao e geograficamente concentrado, confirmando que a causa raiz esta na politica de reposicao global.

P2: Relacao entre volume de vendas e risco de ruptura

faixa_demanda	total_reg	taxa_ruptura	estoque_medio	vendas_medias
Baixa demanda (< P75)	1,090,940	99.4%	236.7	83.1
Alta demanda (>= P75)	371,060	100.0%	385.6	293.5

Produtos de alta demanda atingem 100% de criticidade. A diferenca e marginal mas confirma: maior giro pressiona mais o estoque. Alta demanda tem estoque medio maior (385.6 vs 236.7), mas insuficiente para cobrir 7 dias.

P3: Impacto das promocoes sobre o estoque

rotulo	taxa_critico	vendas_medias	estoque_medio
Com promocao	99.5%	136.42	274.92
Sem promocao	99.5%	136.51	274.03

Promocoes nao geraram impacto mensuravel. As taxas e vendas medias sao praticamente identicas. No dataset sintetico a variavel promocao nao foi correlacionada com aumento de demanda.

P4.1: Variacao mensal da taxa de estoque critico

O grafico mostra a taxa de estoque critico por mes. Meses com taxas acima da media sao candidatos prioritarios para reforco preventivo de estoque antes do periodo.

P4.2: Feriados vs dias normais

rotulo	total	criticos	taxa	vendas_medias
Dia normal	1,462,000	1,455,200	99.5%	136.46

O dataset utilizou holiday_promotion com valores 0/1. Apos separacao, todos os registros foram classificados como dias normais. A estrutura esta preparada para analisar esse impacto com dados reais.

P5: Relacao entre preco e risco de estoque critico (complementar)

faixa_preco	taxa	vendas_medias
Alto preco (> P75)	99.5%	136.82
Baixo preco (<= P25)	99.5%	135.83
Medio preco (P25-P75)	99.6%	136.59
Variacao de precos: min 10.0 max 100.0 desvio padrao 26.02		

Apesar da variacao real de precos (desvio padrao 26.02), as taxas de ruptura sao identicas entre faixas. O preco nao e um fator discriminante neste dataset sintetico.

Conclusao Geral

As cinco analises revelam ruptura **generalizada e uniforme** (aprox. 99.5%), sem diferenciacao significativa por categoria, produto, loja, regioao, promocao ou preco.

Recomendacoes: revisar a politica de reposicao para aumentar o estoque de seguranca, definir pontos de reposicao baseados na demanda media real e monitorar continuamente o indicador `dias_cobertura` com alertas quando cair abaixo de 7 dias.

7. Autoavaliacao

O que foi atingido

- Pipeline completo Bronze > Silver > Gold implementado em notebooks separados
- Regra de negocio para estoque critico definida, documentada e justificada
- Esquema Estrela com tabela fato e 3 dimensoes
- Catalogo de dados completo com tipos, dominio de valores e linhagem para todas as camadas (Bronze, Silver, Gold)
- Verificacao de qualidade em 5 dimensoes
- 5 perguntas de negocio respondidas com analises e visualizacoes em Python

O que ficou limitado

- **P3 e P4.2:** dataset sintetico sem variacao nos campos de promocao e feriado que permitisse diferenciacao.

Dificuldades encontradas

- **Delta Lake com espacos nos nomes de colunas:** erro `DELTA_INVALID_CHARACTERS_IN_COLUMN_NAMES`. Solucao: renomear para `snake_case` antes do `saveAsTable`.
- **Window function com coluna DATE:** `.cast("long")` nao suportado. Solucao: substituir por `.orderBy("data")`.
- **Coluna ambigua no join:** feriado presente em `fato` e `dim_data`. Solucao: `.drop("feriado")` antes do join.
- **Databricks Free Edition:** sem recurso de publicacao de notebooks com link publico.

Trabalhos futuros

- Criar alertas automaticos para produtos com `dias_cobertura < 7` usando Databricks Workflows
- Explorar modelos de previsao de demanda (Prophet, ARIMA) para antecipar rupturas sazonais
- Construir dashboard interativo no Databricks SQL com atualizacao diaria
- Ampliar a analise com dados de multiplos periodos para detectar tendencias de longo prazo