

MVP de Engenharia de Dados

Risco de Ruptura de Estoque no Varejo

Nome: Renata Virginia | Matricula: 4052025002400
Plataforma: Databricks Free Edition | Dataset: Retail Store Inventory Forecasting (Kaggle, CC0)

1. Contexto de Negocios e Perguntas (Etapa 2 e 4.1)

Problema

Uma empresa varejista precisa garantir a disponibilidade dos produtos para atender a demanda. A ocorrencia de niveis insuficientes de estoque resulta em **ruptura**, perda de vendas e pior experiencia para o consumidor. Ao mesmo tempo, estoques excessivos aumentam custos e capital imobilizado.

O objetivo deste projeto e construir um pipeline de dados capaz de identificar padroes associados ao **risco de ruptura de estoque** e gerar informacoes que apoiem decisoes de abastecimento.

Dataset

Nome: Retail Store Inventory Forecasting Dataset
Fonte: Kaggle (Anirudh Chauhan)
Licenca: CC0 (Public Domain) — uso livre, sem necessidade de atribuicao
Volume: 73.100 registros diarios | **Periodo:** 2022-01-01 a 2024-01-01
Conteudo: Lojas, produtos, vendas, estoques, precos, promocoes, feriados e clima

Estrutura dos dados brutos

Coluna original	Tipo	Descricao
Store ID	String	Identificador da loja
Product ID	String	Identificador do produto
Category	String	Categoria do produto
Region	String	Regiao geografica
Date	String	Data do registro
Inventory Level	Integer	Nivel de estoque disponivel
Units Sold	Integer	Unidades vendidas no dia
Units Ordered	Integer	Unidades pedidas/repostas
Demand Forecast	Double	Previsao de demanda
Price	Double	Preco unitario
Discount	Double	Desconto aplicado
Weather Condition	String	Condicao climatica
Holiday/Promotion	String	Indicador de feriado ou promocao
Competitor Pricing	Double	Preco do concorrente
Seasonality	String	Estacao do ano

Regra de negocio: Estoque Critico

```
flag_estoque_critico = True    quando    dias_cobertura < p25(dias_cobertura)
dias_cobertura = nivel_estoque / demanda_media_7d
```

Justificativa: O limiar e o percentil 25 da distribuicao real de `dias_cobertura`, sinalizando os 25% de registros com pior cobertura relativa ao proprio dataset. Um limiar fixo de 7 dias marcaria ~99.5% dos registros como criticos (cobertura media real ~2 dias), tornando a flag inutil como discriminador analitico.

Perguntas de negocio

#	Pergunta
P1	Quais produtos, categorias e lojas tem maior frequencia de estoque critico?
P2	Ha relacao entre alto volume de vendas e maior risco de estoque critico?
P3	Dias com feriado/promocao ativo geram maior pressao sobre o estoque?
P4	Periodos especificos apresentam maior pressao sobre o estoque?
P5	Ha relacao entre preco do produto e risco de estoque critico? (complementar)

2. Carga dos Dados (Etapa 4.2)

O dataset esta disponivel como tabela Delta gerenciada no Unity Catalog: `workspace.default.retail_store_inventory`

Como foi feita a carga

1. Download do arquivo `retail_store_inventory.csv` do Kaggle (CC0)
2. Ingestao como tabela Delta no Unity Catalog
3. Leitura com PySpark via `spark.table()` no notebook `01-bronze-ingestao.py`
4. Renomeacao das colunas para `snake_case` (compatibilidade com Delta Lake)
5. Adicao dos metadados `ingestion_date` e `source_table`
6. Gravacao na camada Bronze: `workspace.bronze.inventory_raw` — **73.100 registros**

Script: notebooks/01_bronze_ingestao.py (repositorio GitHub)

Evidencia: [OK] workspace.bronze.inventory raw gravada com 73,100 registros

Evidencia: tabela de origem no Unity Catalog

workspace.default.retail_store_inventory — colunas originais do dataset (antes da Bronze)


Detalhes: tipo Managed, formato Delta Lake, criada em 30/08/2026

3. Modelagem e Catálogo de Dados (Etapa 4.3)

Arquitetura Medallion

Bronze (dado bruto)	->	Silver (limpo e padronizado)	->	Gold (modelado para análise)
inventory_raw		inventory_clean		fato_estoque_diario
				dim_produto / dim_loja / dim_data

Esquema Estrela (camada Gold)



Catalogo de Dados

bronze.inventory_raw — 73.100 registros. Dado bruto preservado como veio da fonte; colunas renomeadas para snake_case e metadados adicionados.

Coluna	Tipo	Dominio	Descricao
store_id	String	"S001" - "S005" (5 lojas)	Identificador da loja
product_id	String	"P0001" - "P0020" (20 produtos)	Identificador do produto
category	String	Texto livre - dado bruto	Categoria do produto
region	String	Texto livre - dado bruto	Regiao geografica da loja
date	String	Formato "YYYY-MM-DD"	Data do registro
inventory_level	Integer	Sem restricao - dado bruto	Nivel de estoque disponivel
units_sold	Integer	Sem restricao - dado bruto	Unidades vendidas no dia
units_ordered	Integer	Sem restricao - dado bruto	Unidades pedidas/repostas no dia
demand_forecast	Double	Sem restricao - dado bruto	Previsao de demanda
price	Double	Sem restricao - dado bruto	Preco unitario do produto
discount	Integer	Sem restricao - dado bruto	Desconto aplicado (percentual inteiro)
weather_condition	String	Texto livre - dado bruto	Condicao climatica do dia
holiday_promotion	Integer	0 ou 1 - dado bruto	Indicador de feriado ou promocao
competitor_pricing	Double	Sem restricao - dado bruto	Preco do concorrente

seasonality	String	Texto livre - dado bruto	Estacao do ano
ingestion_date	Timestamp	Data/hora da execucao do pipeline	Data/hora da ingestao (metadado)
source_table	String	Sempre "workspace.default.retail_store_inventory_log"	Tabela de origem no Unity Catalog (metadado)

silver.inventory_clean — 73.100 registros. Dados limpos, tipados e padronizados. Registros invalidos removidos; nulos secundarios substituidos por valores padrao.

Coluna	Tipo	Domínio	Descricao
loja_id	String	"S001" - "S005" (5 lojas unicas)	Identificador da loja
produto_id	String	"P0001" - "P0020" (20 produtos unicos)	Identificador do produto
categoria	String	CLOTHING ELECTRONICS FURNITURE GROCERIES TOYS	Categoria do produto (uppercase)
regiao	String	EAST NORTH SOUTH WEST	Regiao geografica da loja (uppercase)
data	Date	2022-01-01 a 2024-01-01	Data do registro
nivel_estoque	Integer	>= 0 (negativos removidos)	Estoque disponivel no dia
unidades_vendidas	Integer	>= 0 (negativos removidos)	Unidades vendidas no dia
unidades_pedidas	Integer	>= 0	Unidades pedidas/repostas no dia
preco_unitario	Double	> 0 (preco <= 0 removido)	Preco unitario do produto
desconto	Double	>= 0 (nulos → 0)	Desconto aplicado no dia
condicao_climatica	String	Cloudy Rainy Snowy Sunny "NAO_INFORMADO"	Condicao climatica do dia
feriado_ou_promocao	Integer	0 ou 1 - nao distingue feriado de promocao	Indicador combinado original (coluna preservada)
feriado_ou_promocao_ativo	Boolean	True / False	Se havia feriado ou promocao no dia (feriado_ou_promocao == 1)
preco_concorrente	Double	>= 0 (nulos → 0)	Preco praticado pelo concorrente
sazonalidade	String	AUTUMN SPRING SUMMER WINTER	Estacao do ano (uppercase)
previsao_demanda	Double	-9,99 a ~518 (dataset sintetico; inclui valores negativos)	Previsao de demanda para o dia

gold.dim_produto — 20 registros (dimensao lean — categoria fica na fato)

Coluna	Tipo	Dominio	Descricao	Linhagem
id_produto	Integer	1 – 20 (surrogate key sequencial)	Chave primaria (PK)	Gerado: row_number() sobre Window.orderBy("produto_id")
produto_id_orig	String	"P0001" - "P0020"	Codigo original do produto	Silver: produto_id
nome_produto	String	"P0001" - "P0020"	Nome do produto	Silver: produto_id

gold.dim_loja — 5 registros (dimensao lean — regioa fica na fato)

Coluna	Tipo	Dominio	Descricao	Linhagem
id_loja	Integer	1 – 5 (surrogate key sequencial)	Chave primaria (PK)	Gerado: row_number() sobre Window.orderBy("loja_id")
loja_id_orig	String	"S001" - "S005"	Codigo original da loja	Silver: loja_id
nome_loja	String	"S001" - "S005"	Nome da loja	Silver: loja_id

gold.dim_data — 731 registros

Coluna	Tipo	Dominio	Descricao	Linhagem
id_data	Integer	Formato yyyyMMdd (ex: 20220101)	Chave primaria (PK)	Gerado: date_format(data, "yyyyMMdd")
data_completa	Date	2022-01-01 a 2024-01-01	Data completa	Silver: data
ano	Integer	2022, 2023, 2024	Ano	Extraido de data_completa
mes	Integer	1 - 12	Numero do mes	Extraido de data_completa
nome_mes	String	January - December	Nome do mes por extenso	Extraido de data_completa
dia_semana	Integer	1 (domingo) - 7 (sabado)	Dia da semana (padrao Spark)	Extraido de data_completa
trimestre	Integer	1 - 4	Trimestre do ano	Extraido de data_completa

Coluna	Tipo	Dominio	Descricao	Linhagem
id_data	Integer	Formato yyyyMMdd (FK → dim_data)	Referencia a dimensao data	Silver: data
id_produto	Integer	1 – 20 (FK → dim_produto)	Referencia a dimensao produto	Silver: produto_id via join com dim_produto
id_loja	Integer	1 – 5 (FK → dim_loja)	Referencia a dimensao loja	Silver: loja_id via join com dim_loja
categoria	String	CLOTHING ELECTRONICS FURNITURE GROCERIES TOYS	Categoria do produto no dia (varia por registro)	Silver: categoria
regiao	String	EAST NORTH SOUTH WEST	Regiao geografica da loja no dia (varia por registro)	Silver: regiao
nivel_estoque	Integer	>= 0	Estoque disponivel no dia	Silver: nivel_estoque
unidades_vendidas	Integer	>= 0	Quantidade vendida no dia	Silver: unidades_vendidas
unidades_pedidas	Integer	>= 0	Quantidade pedida/reposta no dia	Silver: unidades_pedidas
preco_unitario	Double	> 0	Preco unitario do produto	Silver: preco_unitario
desconto	Double	>= 0	Desconto aplicado no dia	Silver: desconto
feriado_ou_promocao_ativo	Boolean	True / False	Se havia feriado ou promocao no dia	Silver: feriado_ou_promocao_ativo
condicao_climatica	String	Cloudy Rainy Snowy Sunny "NAO_INFORMADO"	Condicao climatica	Silver: condicao_climatica
sazonalidade	String	AUTUMN SPRING SUMMER WINTER	Estacao do ano	Silver: sazonalidade
previsao_demanda	Double	-9,99 a ~518 (inclui valores negativos)	Previsao de demanda para o dia	Silver: previsao_demanda
preco_concorrente	Double	>= 0	Preco do concorrente	Silver: preco_concorrente
demanda_media_7d	Double	>= 0	Media movel 7 dias de unidades_vendidas por produto+loja	Calculado: avg(unidades_vendidas) — Window 7 dias
dias_cobertura	Double	0 a 999 (999 = sem demanda)	Dias ate esgotamento do estoque	Calculado: nivel_estoque / demanda_media_7d

flag_estoque_critico	Boolean	True para os 25% com menor cobertura relativa	Indicador de risco de ruptura	Calculado: dias_cobertura < p25(dias_cobertura)
----------------------	---------	---	-------------------------------	---

Evidencias no Unity Catalog (Databricks)

As tabelas foram criadas e registradas no Unity Catalog do Databricks Free Edition sob o catalogo workspace. As capturas de tela completas constam na versao HTML deste relatorio.

Schema	Tabela(s)	Registros
workspace.bronze	inventory_raw	73.100
workspace.silver	inventory_clean	73.100
workspace.gold	dim_produto, dim_loja, dim_data, fato_estoque_diario	20 / 5 / 731 / 73.100

4. Pipeline de Dados (Etapa 4.4)

O pipeline foi organizado em **5 notebooks separados por responsabilidade**, seguindo a Arquitetura Medallion.

Notebook	Camada	Responsabilidade
01_bronze_ingestao.py	Bronze	Leitura da tabela de origem e gravacao sem transformacoes
02_silver_transformacao.py	Silver	Limpeza, padronizacao e remocao de duplicatas
03_gold_modelagem.py	Gold	Esquema Estrela e aplicacao da regra de ruptura
04_qualidade_dados.py	Bronze/Silver/Gold	Verificacao de qualidade nas tres camadas
05_analise_negocio.py	Gold	Resposta as 5 perguntas com visualizacoes

Tambem foi criado o 00_pipeline_completo.py que executa todas as etapas em sequencia.

Transformacoes (Silver)

Transformacao	Decisao
Renomeacao de colunas	Nomes padronizados em portuges
Conversao de tipos	data para DateType, numericos para Int/Double
Indicador feriado/promocao	Criado feriado_ou_promocao_ativo (0/1 cast para Boolean; coluna original nao distingue feriado de promocao)
Padronizacao strings	Trim + uppercase em categorias, regioes e sazonalidade
Duplicatas	Removidas por chave loja_id + produto_id + data
Nulos essenciais	Linhas com nivel_estoque ou unidades_vendidas nulos removidas
Valores impossiveis	Estoque/vendas negativos e preco zero removidos

Evidencia: tabelas salvas no Databricks

```
=== Contagem por tabela Gold ===
dim_produto      :      20
dim_loja         :       5
dim_data        :     731
fato_estoque_diario :   73,100

=== Validacao obrigatoria ===
[OK] fato = silver = 73,100 registros

=== Integridade referencial (chaves nulas na fato) ===
id_produto nulos: 0 [OK]
id_loja nulos  : 0 [OK]
id_data nulos  : 0 [OK]

Bronze: workspace.bronze.inventory_raw    -> 73,100 registros [OK]
Silver: workspace.silver.inventory_clean  -> 73,100 registros [OK]
Gold:   workspace.gold.fato_estoque_diario -> 73,100 registros [OK]
```

Evidencia de persistencia das tabelas na plataforma de nuvem

Os tres schemas (bronze, silver e gold) foram persistidos no catalogo workspace do Databricks Free Edition em formato Delta Lake gerenciado. As capturas de tela do Unity Catalog constam na versao HTML deste relatorio.

5. Qualidade de Dados (Etapa 4.5)

Compleitude: Valores Nulos

```
BRONZE: inventory_raw | 73,100 registros | [OK] Todas as colunas -> 0 nulos (0.0%)
SILVER: inventory_clean| 73,100 registros | [OK] Todas as colunas -> 0 nulos (0.0%)
GOLD:   fato_estoque   | 73,100 registros | [OK] Todas as colunas -> 0 nulos (0.0%)
```

Unicidade: Duplicatas

```
Total de registros      : 73,100
Chaves unicas           : 73,100 (loja_id + produto_id + data)
Duplicatas detectadas: 0
[OK] Nenhuma duplicata encontrada.
```

Consistencia: Dominios e Formatos

```
Faixa de datas: 2022-01-01 a 2024-01-01 (2 anos completos)
Categorias (5): CLOTHING | ELECTRONICS | FURNITURE | GROCERIES | TOYS
Regioes (4):    EAST | NORTH | SOUTH | WEST
Clima:          Cloudy | Rainy | Snowy | Sunny
Sazonalidade:   AUTUMN | SPRING | SUMMER | WINTER
```

Acuracia e Outliers

```
Valores impossiveis:
Estoque negativo      : 0 [OK]
Vendas negativas      : 0 [OK]
Preco zero ou negativo : 0 [OK]
Cobertura negativa    : 0 [OK]

Estatisticas descritivas (Silver):
nivel_estoque | media: 274.5 | min: 0 | max: 1000
unidades_vendidas | media: 136.5 | min: 0 | max: 400
preco_unitario  | media: 50.0 | min: 10.0 | max: 100

Distribuicao da flag de estoque critico (limiar = p25 de dias_cobertura):
true (critico): 18,275 registros (25.0%)
false (normal) : 54,825 registros (75.0%)

Limiar adaptativo calculado: p25(dias_cobertura) ~ 1.43 dias
```

6. Analise de Dados (Etapa 4.5)

Nota metodologica: A flag de estoque critico usa limiar adaptativo (percentil 25 de dias_cobertura), marcando exatamente os 25% de registros com pior cobertura relativa. Por isso, as taxas gerais giram em torno de 25%. Onde ha diferenciacao real (ex.: P2), o discriminador funciona corretamente.

P1.1: Taxa de estoque critico por categoria

categoria	total_dias	dias_criticos	pct_critico
ELECTRONICS	14,600	3,650	25.0%
CLOTHING	14,600	3,621	24.8%
GROCERIES	14,600	3,621	24.8%
TOYS	14,600	3,606	24.7%
FURNITURE	14,600	3,592	24.6%

Todas as categorias apresentam taxa proxima a 25% (Electronics lidera com 25.0%, Furniture fecha com 24.6%). A variacao de apenas 0.4pp indica que o risco de ruptura e distribuido de forma uniforme entre segmentos, sem concentracao em categorias especificas. O problema e estrutural, nao setorial.

P1.2: Top 15 produtos com maior taxa critica

Os 15 produtos mais criticos apresentam taxas entre 26% e 28%, acima da media geral de 25%. Esses produtos sao candidatos prioritarios para revisao do ponto de reposicao e formacao de estoque de seguranca dedicado.

P1.3: Estoque critico por loja e regioao

As 5 lojas e 4 regioes apresentam taxas proximas a 25%. A ausencia de concentracao geografica confirma que o problema nao e operacional de uma unidade especifica, mas sistemico na politica de reposicao da rede.

P2: Relacao entre volume de vendas e risco de ruptura

faixa_demanda	total_reg	taxa_critico	estoque_medio
Baixa demanda (< P75)	54,825	32.4%	237.6
Alta demanda (>= P75)	18,275	1.4%	387.4

Este e o achado mais relevante: produtos de BAIXA demanda tem taxa critica de 32.4%, enquanto produtos de ALTA demanda tem apenas 1.4%. Paradoxalmente, produtos de alto giro recebem mais estoque (387.4 vs 237.6 unidades), o que protege sua cobertura. O risco de ruptura esta concentrado nos produtos de menor visibilidade comercial.

P3: Dias com feriado/promocao ativo vs sem evento

rotulo	taxa_critico	vendas_medias	estoque_medio
Feriado/Promocao ativo	24.5%	136.42	274.92
Sem feriado/promocao	25.0%	136.51	274.03

O indicador feriado_ou_promocao_ativo nao discrimina risco: taxas de 24.5% e 25.0% sao estatisticamente equivalentes. Vendas medias identicas (136.42 vs 136.51) confirmam que o dataset sintetico nao codificou variacao de demanda associada a eventos. Limitacao do dado: a coluna original nao distingue feriado de promocao.

P4.1: Variacao mensal da taxa de estoque critico

Ha variacao sazonal visivel: marco e setembro registram os menores valores (23.8%) e dezembro o maior (25.6%). A amplitude de 1.8pp e modesta, mas o padrao sugere que o final do ano concentra maior pressao sobre o estoque — periodo compativel com datas comemorativas e aumento de demanda tipico do varejo.

P4.2: Dias com evento (feriado/promocao) vs dias normais

rotulo	total	criticos	taxa	vendas_medias
Feriado/Promocao ativo	36,550	8,955	24.5%	136.42
Dia normal	36,550	9,135	25.0%	136.51

Dias com evento e dias normais apresentam taxas identicas (24.5% vs 25.0%) e vendas medias equivalentes. O indicador binario 0/1 nao captura diferenciacao de risco, o que e esperado para um dataset sintetico. Em dados reais, este comparativo revelaria se acoes promocionais e feriados geram picos de demanda nao cobertos pelo estoque.

P5: Relacao entre preco e risco de estoque critico (complementar)

faixa_preco	taxa	vendas_medias
Alto preco (> P75)	~25%	136.82
Baixo preco (<= P25)	~25%	135.83
Medio preco (P25-P75)	~25%	136.59

Variacao de precos: min 10.0 | max 100.0 | desvio padrao 26.02

Apesar da variacao real de precos (desvio padrao 26.02, amplitude de R\$10 a R\$100), as taxas criticas sao identicas entre faixas (~25%). O preco nao e um fator discriminante neste dataset sintetico, o que e esperado: o risco de ruptura depende de politica de reposicao, nao de preco.

Conclusao Geral

O achado mais relevante e de P2: produtos de **baixa demanda concentram 32.4% de dias criticos**, enquanto os de alta demanda tem apenas 1.4%. Isso e contraintuitivo — produtos de alto giro recebem mais estoque e sao menos vulneraveis a ruptura. O risco esta nos produtos de menor visibilidade comercial.

P1, P3, P4 e P5 mostram taxas proximas a 25% em todas as dimensoes, o que e esperado dado o criterio adaptativo (p25). O dataset sintetico nao codificou variacao de demanda por evento ou preco.

Recomendacoes: priorizar o reabastecimento de produtos de baixa demanda com estoque cronicamente baixo; monitorar dias_cobertura com alertas automaticos para o quartil inferior; e incorporar sazonalidade mensal (dezembro concentra pico) no calendario de compras.

7. Autoavaliacao

O que foi atingido

- Pipeline completo Bronze > Silver > Gold implementado em notebooks separados
- Regra de negocio para estoque critico definida com limiar adaptativo (p25 de dias_cobertura), documentada e justificada
- Esquema Estrela com tabela fato e 3 dimensoes
- Catalogo de dados completo com tipos, dominio de valores e linhagem para todas as camadas (Bronze, Silver, Gold)
- Verificacao de qualidade em 5 dimensoes
- 5 perguntas de negocio respondidas com analises e visualizacoes em Python

O que ficou limitado

- **P3 e P4.2:** a coluna original `feriado_ou_promocao` e um inteiro binario (0/1) que nao distingue feriado de promocao. O indicador unificado nao apresentou diferenciacao de risco, o que e esperado para dados sinteticos sem variacao de demanda por evento.

Dificuldades encontradas

- **Delta Lake com espacos nos nomes de colunas:** erro `DELTA_INVALID_CHARACTERS_IN_COLUMN_NAMES`. Solucao: renomear para `snake_case` antes do `saveAsTable`.
- **Window function com coluna DATE:** `.cast("long")` nao suportado. Solucao: substituir por `.orderBy("data")`.
- **Coluna feriado_ou_promocao:** dado original e inteiro 0/1 sem distincao entre feriado e promocao. Criado indicador unico `feriado_ou_promocao_ativo`; analises P3 e P4.2 usam o indicador unificado.
- **Databricks Free Edition:** sem recurso de publicacao de notebooks com link publico.

Trabalhos futuros

- Criar alertas automaticos para `flag_estoque_critico = True` usando Databricks Workflows
- Explorar modelos de previsao de demanda (Prophet, ARIMA) para antecipar rupturas sazonais
- Construir dashboard interativo no Databricks SQL com atualizacao diaria
- Ampliar a analise com dados de multiplos periodos para detectar tendencias de longo prazo